

UNIVERSIDAD NACIONAL MAYOR DE SAN MARCOS

(Universidad del Perú, Decana de América)

Facultad de Ingeniería de Sistemas e Informática

Escuela Profesional de Ingeniería de Software



INTELIGENCIA DE NEGOCIOS

FISIMART

DOCENTE:

GAMARRA MORENO, JUAN

Integrantes:

- Astuhuaman Vega, Max Steven
- Calle Ramos Guillermo Javier
- Luján Vila, Frank José
- Rouillon Haro, Favio
- Villanueva Aguirre, Cesar Alexander

LIMA, PERÚ

ÍNDICE

1. Resumen ejecutivo del proyecto y de los principales hallazgos.....	4
2. Descripción de la empresa ficticia: FISIMart S.A.C.....	5
2.1. Problemática de negocio.....	5
2.2. Preguntas de negocio.....	5
3. Generación de datos sintéticos.....	6
3.1. Esquema del dataset sintético.....	6
3.2. Volúmenes de Datos.....	6
3.3. Distribuciones estadísticas y reglas de realismo analítico.....	7
3.4. Problemas de calidad introducidos a propósito.....	7
4. Parte 1 — Datamart analítico.....	8
4.1. Diagrama del esquema estrella.....	8
4.2. Diccionario de datos.....	9
4.2.1. Tabla de hechos: Fact_Ventas.....	9
4.2.2. Tabla dimensional: Dim_Cliente.....	9
4.2.3. Tabla dimensional: Dim_Producto.....	10
4.2.4. Tabla dimensional: Dim_Tienda.....	10
4.2.5. Tabla dimensional: Dim_Tiempo.....	11
4.2.6. Tabla dimensional: Dim_Promocion.....	11
4.3. Captura del modelo en Power BI.....	12
5. Parte 2 — Visualización: tablero, medidas DAX e insights.....	12
5.1. Medidas DAX.....	12
5.2. Recomendación de negocio.....	13
6. Parte 3 — Clasificación: definición, modelos, evaluación e interpretación.....	16
6.1. Definición del problema.....	16
6.2. Construcción del dataset de clasificación.....	16
6.3. Modelos implementados.....	19
6.4. Evaluación del desempeño.....	20
6.5. Interpretación del modelo.....	23
6.6. Recomendaciones de negocio.....	24
7. Parte 4 — Segmentación: RFM, clusters, perfiles y estrategias.....	26
7.1. Metodología: construcción del RFM y clustering.....	26
7.2. Segmentos resultantes y perfiles.....	27
7.3. Hallazgo clave: validación del diseño del dataset.....	29
7.4. Estrategias diferenciadas por segmento.....	29
8. Parte 5 — Asociación: reglas y propuestas de venta cruzada.....	30
8.1. Metodología: construcción de canastas y minería de reglas.....	30
8.2. Reglas de Asociación.....	31
8.3. Recomendaciones de venta cruzada.....	32
9. Parte 6 — Regresión: pronóstico, métricas y recomendaciones.....	33

9.1. Objetivo y alcance.....	33
9.2. Fuentes de datos utilizadas.....	33
9.3. Definición de la variable objetivo.....	34
9.4. Construcción de variables predictoras.....	34
9.5. División temporal de entrenamiento y prueba.....	36
9.6. Modelos evaluados.....	37
9.7. Resultados y comparación de métricas.....	37
9.8. Selección del mejor modelo y análisis del pronóstico.....	38
9.9. Interpretación de variables y hallazgos de negocio.....	39
9.10. Recomendaciones de planificación.....	40
10. Reflexión ética y de integridad; anexo de prompts A y B.....	40
11. Conclusiones, recomendaciones y tabla de contribución por integrante.....	40
11.1. Conclusiones.....	40
11.2. Recomendaciones.....	41
11.3. Tabla de contribución por integrante.....	42

1. Resumen ejecutivo del proyecto y de los principales hallazgos.

El presente proyecto desarrolló una solución integral de Inteligencia de Negocios para FISIMart S.A.C., empresa peruana ficticia de retail minorista con 20 puntos de venta en Lima Metropolitana y un programa de fidelización de 5,000 clientes. A partir de un dataset sintético de 25,000 transacciones generadas bajo reglas de realismo analítico (estacionalidad peruana, concentración de Pareto y patrón de churn deliberado), se construyó un datamart en esquema estrella y se ejecutaron cinco análisis complementarios que responden a las preguntas de negocio planteadas.

Los principales hallazgos por componente son los siguientes:

Visualización (Parte 2). Las ventas y el margen presentan una sincronía lineal estable a lo largo del periodo 2024–2025, con picos de facturación concentrados en julio y diciembre. El análisis de Pareto determinó que 12 SKU sostienen el 80% de la facturación global, liderados por productos de la canasta básica y bebidas de alta rotación.

Clasificación / Churn (Parte 3). El modelo de Random Forest identificó con alta confiabilidad a los clientes con mayor probabilidad de abandono del programa de fidelización, concentrando el riesgo en el segmento Básico con menores ingresos mensuales, quienes cesaron su actividad de compra durante los últimos cuatro meses de 2025.

Segmentación RFM (Parte 4). K-Means con $k=4$ (silhouette 0.43) produjo cuatro arquetipos: Campeones (7.0%, Recency 57 días, $S/ 2,855$ promedio), Leales (23.9%), En Riesgo (39.7%) y Perdidos (29.4%, Recency 469 días). El cluster Perdidos capturó con precisión el 22.9% de clientes Básico de bajos ingresos que dejaron de comprar, validando el diseño del dataset y conectando el resultado con el análisis de churn.

Asociación (Parte 5). El algoritmo Apriori identificó 38 reglas de asociación relevantes. La relación más fuerte encontrada vincula Cervezas 29 con Dental 97 (lift 1.92), evidenciando patrones de compra cruzada entre categorías aparentemente distantes y abriendo oportunidades de cross-merchandising y bundles promocionales.

Regresión / Pronóstico (Parte 6). La Regresión Lineal obtuvo el mejor desempeño para pronosticar la demanda diaria ($R^2 = 0.842$, $MAE = S/ 727.44$, $MAPE = 24.96\%$), superando a Random Forest y Gradient Boosting. Los feriados ($+S/ 611.79/\text{día}$) y los fines de semana ($+S/ 308.03/\text{día}$) resultaron ser los factores individuales de mayor impacto sobre las ventas diarias.

En conjunto, los seis componentes demuestran que una solución integrada de BI proporciona información complementaria y accionable para las áreas comercial, de marketing y de inventario de FISIMart. Dado que el estudio se realizó sobre datos sintéticos, los resultados constituyen una prueba de concepto que requiere validación con datos transaccionales reales antes de su despliegue operativo.

2. Descripción de la empresa ficticia: FISIMart S.A.C.

FISIMart S.A.C. es una empresa peruana emergente de retail minorista con operaciones centradas en Lima Metropolitana, fundada por alumnos de la Universidad Nacional Mayor de San Marcos a inicios de 2024 como una iniciativa de modernización comercial estructurado en dos frentes principales:

- **Canal Físico:** Una red de 18 sucursales distribuidas estratégicamente en zonas clave y de alta densidad de Lima (como Miraflores, San Borja, Comas, Los Olivos, Santiago de Surco, entre otros).
- **Canal Online (Ecommerce):** Dos plataformas virtuales de comercio electrónico que centralizan la demanda digital a nivel provincial.

Para potenciar la retención de clientes y competir en el mercado frente a grandes conglomerados, FISIMart implementó desde su primer día un Programa de Fidelización Digital, segmentando a sus usuarios en cuatro categorías (Básico, Regular, Premium y Platino) según su comportamiento de compra. La empresa comercializa un catálogo de 600 productos clasificados en cinco categorías estratégicas de alta rotación: Abarrotes, Tecnología, Hogar, Bebidas y Cuidado Personal.

2.1. Problemática de negocio

A pesar de su rápido crecimiento transaccional, el equipo directivo de FISIMart S.A.C ha identificado los siguientes problemas operativos y analíticos:

- Los sistemas transaccionales de las cajas físicas y el sistema del Ecommerce registran la información de manera heterogénea.
- Se sospecha de una deserción masiva de clientes del programa de fidelización, sin embargo, la falta de una matriz analítica unificada impide calcular la tasa de abandono real y sus detonantes.
- La empresa sufre de quiebres de stock en meses de alta estacionalidad comercial peruana y sobrestock innecesario en los meses de contracción del consumo.
- Las promociones comerciales de marketing se lanzan de manera masiva y sin personalización.

2.2. Preguntas de negocio

Se establecen las siguientes preguntas:

- ¿Cómo evolucionan las ventas y el margen por categoría, tienda, canal y periodo? (Partes 1 y 2)
- ¿Qué clientes tienen mayor probabilidad de abandonar el programa de fidelización? (Parte 3)

- ¿Qué segmentos de clientes existen y cómo debería tratarse a cada uno? (Parte 4)
- ¿Qué productos se compran juntos y qué promociones cruzadas conviene impulsar? (Parte 5)
- ¿Cuál será la demanda/venta esperada para planificar inventario y campañas? (Parte 6)

3. Generación de datos sintéticos

Para el desarrollo del Datamart y la validación de los modelos predictivos, se construyó un pipeline de simulación en Python utilizando las librerías pandas, numpy y faker, con el fin de garantizar la estricta reproducibilidad de los experimentos y la consistencia matemática de los datos en futuras ejecuciones, se fijó globalmente la semilla aleatoria **SEMILLA = 20** en todos los generadores estocásticos.

3.1. Esquema del dataset sintético

El conjunto de datos crudos tiene una estructura de una base de datos relacional transaccional, diseñada para ser normalizada en un esquema Estrella, y está compuesto por seis archivos planos independientes:

- clientes_raw.csv: Registro de clientes inscritos en el programa de fidelización.
- productos_raw.csv: Catálogo de productos disponibles con sus costos y precios sugeridos.
- tiendas_raw.csv: Estructura de los canales de venta físicos y virtuales.
- tiempo_raw.csv: Calendario base para el análisis temporal de las operaciones.
- promociones_raw.csv: Registro de campañas de marketing y descuentos vigentes.
- ventas_raw.csv: Tabla de hechos centralizada que almacena las líneas de boleta de cada transacción.

3.2. Volúmenes de Datos

Siguiendo las restricciones de negocio impuestas en la rúbrica, se generó los siguientes volúmenes exactos de información en su estado base:

- Dim_Cliente: 5,000 registros únicos de consumidores.
- Dim_Producto: 600 códigos de producto (SKU) diferenciados.
- Dim_Tienda: 20 puntos de venta comerciales (18 Tiendas Físicas en Lima Metropolitana y 2 plataformas de Ecommerce/Online).
- Dim_Tiempo: 731 días calendario, cubriendo un horizonte temporal completo de 2 años (periodo 2024 y 2025).
- Dim_Promocion: 41 campañas de descuento parametrizadas (más un registro técnico base PROMO_NONE para ventas sin campaña).
- Fact_Ventas: 25,743 líneas de transacción base (que se incrementan en el archivo raw debido a la inyección planificada de duplicados).

3.3. Distribuciones estadísticas y reglas de realismo analítico

Para evitar que los datos fuesen puramente aleatorios y carecieran de valor predictivo, se inyectaron cuatro comportamientos matemáticos basados en la realidad del retail peruano:

- Concentración de Pareto (Regla 80/20): Se aplicó una distribución exponencial en la asignación de compras, lo que provocó de forma controlada que un 20% de los productos representen el 80% de las transacciones, y que un grupo selecto de clientes actúen como compradores "muy frecuentes" mientras la mayoría se comporta como cliente "esporádico".
- Se introdujeron multiplicadores de demanda mensuales para replicar el comportamiento del consumidor local.
- Se programó una regla de co-ocurrencia lógica, si un cliente agrega un producto de la categoría Abarrotes (ej. Snacks), el algoritmo eleva al 78% la probabilidad de agregar un producto de Bebidas en el mismo identificador de venta (id_venta), forzando un indicador de Lift > 1.
- Se definió matemáticamente que un 23% de la población de clientes (con correlación directa a menores ingresos mensuales y pertenecientes al segmento Básico) cesara por completo cualquier actividad de compra durante los últimos cuatro meses del año 2025, dejando una firma analítica óptima para algoritmos de clasificación.

3.4. Problemas de calidad introducidos a propósito


Se alteró intencionalmente el archivo crudo introduciendo las siguientes anomalías de calidad:

Tabla	Tipo de anomalía	Descripción	Afectación
Dim_Cliente	Valores nulos (NaN)	Ausencia de datos para simular omisiones en el registro.	1.50%
	Fechas Heterogéneas	Rompe el formato estándar (YYYY-MM-DD) mezclándolo con formatos mixtos.	2.00%
Dim_Producto	Valores nulos (NaN)	SKUs genéricos o sin marca registrada (marca = NaN).	2.00%
	Texto Sucio y Errores de Típo	Inconsistencia tipográfica en categoría	25.00%
Dim_Tienda	Valores nulos (NaN)	Pérdida del nombre comercial de la sucursal.	1.00%
Dim_Tiempo	Valores nulos (NaN)	Falla de carga en el calendario.	1.00%
Fact_Ventas	Valores nulos (NaN)	Omisión de registro en la columna descuento	1.50%
	Fechas Heterogéneas	Rompe el formato estándar (YYYY-MM-DD) mezclándolo con formatos mixtos.	2.00%

	Registros Duplicados	Filas idénticas añadidas para simular errores de envío.	1.00%
	Outliers Severos (Atípicos)	Transacciones corruptas con cantidad alterada	0.30%
	Ruptura de Integridad Referencial	Registros huérfanos que apuntan a un código de producto inexistente (PROD9999)	0.30%

4. Parte 1 — Datamart analítico

4.1. Diagrama del esquema estrella



4.2. Diccionario de datos

4.2.1. Tabla de hechos: Fact_Ventas

CAMPO	TIPO	CLAVE	DESCRIPCIÓN
id_venta	VARCHAR(20)	PK	Código único de la boleta o ticket de compra.
fecha	DATE	FK	Fecha de la venta. Conecta con Dim_Tiempo.
id_cliente	VARCHAR(20)	FK	Identificador del cliente. Conecta con Dim_Cliente.
id_producto	VARCHAR(20)	FK	Identificador del producto. Conecta con Dim_Producto.
id_tienda	VARCHAR(20)	FK	Identificador de la sucursal. Conecta con Dim_Tienda.
id_promocion	VARCHAR(20)	FK	Identificador de campaña aplicada. Conecta con Dim_Promocion.
cantidad	INTEGER	-	Número de unidades físicas vendidas en la línea.
precio_unitario	DECIMAL(10,2)	-	Precio real de venta unitario cobrado en caja
descuento	DECIMAL(3,2)	-	Porcentaje de descuento aplicado (0.00 a 0.30).
importe	DECIMAL(12,2)	-	Métrica calculada: cantidad x precio_unitario x (1 - descuento)
costo_total	DECIMAL(12,2)	-	Métrica calculada: cantidad x costo_unitario.
margen	DECIMAL(12,2)	-	Métrica calculada: importe - costo_total.

4.2.2. Tabla dimensional: Dim_Cliente

CAMPO	TIPO	CLAVE	DESCRIPCIÓN
id_cliente	VARCHAR(20)	PK	Código único del cliente
nombre	VARCHAR(150)	-	Nombre completo del cliente
sexo	CHAR(1)	-	Género biológico registrado (M / F)
fecha_nacimiento	DATE	-	Fecha de nacimiento del cliente.
edad	INTEGER	-	Edad del cliente calculada en años.

distrito	VARCHAR(100)	-	Distrito residencial en Lima (o "No Especificado").
fecha_alta	DATE	-	Fecha de registro en el programa de lealtad FISIMart.
segmento_programa	VARCHAR(50)	-	Nivel de cliente (Basico, Regular, Premium, Platino).
ingresos_mensuales_aprox	DECIMAL(10,2)	-	Remuneración mensual estimada en Soles.

4.2.3. Tabla dimensional: Dim_Producto

CAMPO	TIPO	CLAVE	DESCRIPCIÓN
id_producto	VARCHAR(20)	PK	Código único del SKU
nombre	VARCHAR(150)	-	Descripción comercial del artículo.
categoria	VARCHAR(50)	-	Agrupador estratégico (Abarrotes, Bebidas, Tecnología, Hogar, Cuidado Personal).
subcategoria	VARCHAR(50)	-	Sub-categoría asociada al negocio.
marca	VARCHAR(50)	-	Nombre del fabricante o marca propia.
precio_lista	DECIMAL(10,2)	-	Precio de catálogo regular sugerido al público.
costo	DECIMAL(10,2)	-	Costo de adquisición unitario del inventario.

4.2.4. Tabla dimensional: Dim_Tienda

CAMPO	TIPO	CLAVE	DESCRIPCIÓN
id_tienda	VARCHAR(20)	PK	Identificador de la tienda.
nombre	VARCHAR(100)	-	Nombre descriptivo de la tienda física o Ecommerce.
canal	VARCHAR(20)	-	Formato omnicanal (Físico / Online).
region	VARCHAR(50)	-	Ubicación geográfica regional
ciudad	VARCHAR(50)	-	Ciudad de operación.


4.2.5. Tabla dimensional: Dim_Tiempo

CAMPO	TIPO	CLAVE	DESCRIPCIÓN
fecha	DATE	PK	Clave primaria calendario (Formato base YYYY-MM-DD).
dia	INTEGER	-	Día numérico del mes (1 al 31).
mes	INTEGER	-	Número de mes (1 al 12).
trimestre	INTEGER	-	Número de trimestre del año (1 al 4).
anio	INTEGER	-	Año calendario (2024 o 2025).
dia_semana	VARCHAR(20)	-	Nombre literal del día (Monday, Tuesday, etc.).
es_feriado	BIT / INT	-	Bandera indicadora (1 = Feriado oficial peruano, 0 = Ordinario).

4.2.6. Tabla dimensional: Dim_Promocion

CAMPO	TIPO	CLAVE	DESCRIPCIÓN
id_promocion	VARCHAR(20)	PK	Identificador de campaña.
nombre	VARCHAR(100)	-	Nombre comercial de la campaña de marketing.
tipo	VARCHAR(50)	-	Mecánica de promoción (Descuento directo, volumen, estacional).
descuento_pct	DECIMAL(3,2)	-	Tasa nominal de descuento aplicable (0.05 a 0.30).
fecha_inicio	DATE	-	Apertura de vigencia de la campaña.
fecha_fin	DATE	-	Cierre y expiración de la campaña.

4.3. Captura del modelo en Power BI




5. Parte 2 — Visualización: tablero, medidas DAX e insights.


5.1. Medidas DAX

- Ventas_Totales = SUM(Fact_Ventas[importe])
- Costo_Total = SUM(Fact_Ventas[costo_total])
- Margen_Total = SUM(Fact_Ventas[margen])
- Margen Real = DIVIDE(SUM(Fact_Ventas[margen]), SUM(Fact_Ventas[importe]), 0)
- Porcentaje_Margen = DIVIDE([Margen_Total], [Ventas_Totales], 0)
- Unidades_Vendidas = SUM(Fact_Ventas[cantidad])
- Ticket_Promedio = DIVIDE([Ventas_Totales], DISTINCTCOUNT(Fact_Ventas[id_venta]), 0)
- Clientes_Activos = DISTINCTCOUNT(Fact_Ventas[id_cliente])


5.2. Recomendación de negocio




- La sincronía e incrementalidad lineal observada entre la curva de ventas totales y el margen comercial absoluto mes a mes demuestra que las políticas de precios y los niveles de descuento aplicados por la empresa son financieramente estables, dado que no existen brechas atípicas que evidencien una erosión de la rentabilidad por rebajas descontroladas, la recomendación de negocio es dar continuidad formal al esquema comercial vigente y utilizarlo para que el área financiera proyecte presupuestos operativos y flujos de caja a largo plazo con un nivel mínimo de incertidumbre.



- El análisis de Pareto determinó una concentración crítica en el catálogo de productos, revelando que un grupo selecto de solo 12 artículos sostiene el 80% de la facturación global de la compañía, al identificarse que está liderado por productos de la canasta básica y de altísima rotación, la recomendación comercial es implementar auditorías de stock diario exclusivas para estos SKU Clase A.



- Las presentaciones familiares de bebidas, se posicionan firmemente dentro del Top 5 de los productos con mayor recaudación, y debido a que actúan como imanes naturales de compra, la recomendación de negocio es redistribuir físicamente el layout de las sucursales, ubicando estos artículos en las zonas más profundas de los pasillos comerciales, de este modo, se obliga al cliente a transitar por una mayor superficie de la tienda, maximizando la exposición e incentivando la compra cruzada de productos complementarios.
- Existe una brecha importante en el rendimiento de la categoría de Tecnología, la cual genera un volumen considerable de ingresos brutos, pero reporta un margen comercial proporcionalmente relativamente ajustado debido a sus elevados costos de adquisición, por lo que se recomienda restringir las campañas de descuento directo sobre el precio, y en su lugar estructurar dinámicas de empaquetamiento comercial que vinculen el producto tecnológico principal con accesorios complementarios de marca propia o alta rentabilidad.



- La matriz de calor identificó un comportamiento altamente estacional en las ventas de la empresa, destacando a diciembre como el pico comercial absoluto del año y a julio como el segundo más importante debido a las campañas de fin de año y Fiestas Patrias, por lo que se recomienda emitir las órdenes de abastecimiento masivo de alta rotación con un desfase anticipado de 45 días, blindando la operación logística contra retrasos de distribución en las temporadas más lucrativas.
- El mapa de calor expuso una meseta comercial prolongada (zonas frías) durante los bloques de enero a junio y de agosto a noviembre, periodos donde la facturación de la mayoría de categorías se ralentiza notablemente, para contrarrestar esta desaceleración la recomendación de negocio es activar promociones de cupones de recompra y packs temáticos estacionales enfocados en retener la frecuencia de visita del cliente habitual en los meses de bajo tráfico.

6. Parte 3 — Clasificación: definición, modelos, evaluación e interpretación.

6.1. Definición del problema

La pregunta de negocio "¿Qué clientes tienen mayor probabilidad de abandonar el programa de fidelización?" corresponde, desde el punto de vista analítico, a un problema de **clasificación supervisada binaria**. A diferencia de un problema de regresión, donde se busca predecir una magnitud continua, aquí el objetivo es predecir una etiqueta categórica y mutuamente excluyente: si un cliente **abandona** (`churn = 1`) o **permanece activo** (`churn = 0`) dentro del programa de fidelización de FISIMart S.A.C. Esta naturaleza binaria del fenómeno, sumada a la disponibilidad de un historial transaccional etiquetable a partir del comportamiento observado, hace que los algoritmos de clasificación supervisada (Regresión Logística, Árbol de Decisión y Random Forest) sean la herramienta metodológica adecuada, en contraposición a técnicas no supervisadas como el clustering, que no requieren una variable objetivo definida a priori.

El objetivo de negocio detrás de este ejercicio es doble. En primer lugar, busca **anticipar** el abandono antes de que este ocurra, transformando la incertidumbre operativa señalada por el directorio de FISIMart —la sospecha de una deserción masiva sin una matriz analítica unificada que permitiera cuantificarla— en un indicador cuantificable y accionable. En segundo lugar, busca **explicar** el fenómeno, es decir, no basta con generar una predicción binaria por cliente; se requiere identificar cuáles son las variables o "detonantes" del comportamiento de abandono, de manera que el equipo de retención de FISIMart pueda diseñar campañas de fidelización diferenciadas y basadas en evidencia, en lugar de continuar con el esquema de promociones masivas y sin personalización que hoy afecta a la compañía.

6.2. Construcción del dataset de clasificación

Dado que ninguna tabla del modelo estrella construido en la Parte 1 contiene una bandera explícita de abandono, la variable objetivo `churn` tuvo que **derivarse del comportamiento transaccional** de cada cliente, siguiendo un diseño metodológico que blindó al modelo contra la fuga de información temporal (*data leakage*). Para ello, se definieron dos ventanas de tiempo mutuamente excluyentes sobre `df_master`: una **ventana de observación** (hasta el 31 de agosto de 2025), única fuente permitida para calcular las variables predictoras, y una **ventana de resultado** (del 1 de septiembre al 31 de diciembre de 2025), única fuente permitida para construir la etiqueta. Un cliente elegible — es decir, con al menos una transacción dentro de la ventana de observación — se etiquetó como `churn = 1` si no registró ninguna transacción durante la ventana de resultado, y como `churn = 0` en caso contrario.


Sobre esta base, el pipeline de preparación de datos siguió un proceso en dos etapas. En la **Etapa A**, las líneas de venta de `df_obs` se consolidaron a nivel de boleta (`id_venta`), evitando que una boleta con múltiples líneas de producto pesara artificialmente más que una boleta de una sola línea al momento de calcular frecuencia o monto de compra. En la

Etapa B, sobre esta tabla de boletas ya consolidada, se construyó el vector de variables a nivel cliente, compuesto por indicadores clásicos de tipo RFM (*recencia_dias*, *frecuencia_compras*, *monto_total*, *margen_total_generado*), hábitos de consumo (*ticket_promedio*, *n_tiendas_distintas*, *pct_canal_online*, *pct_boletas_con_promocion*, *descuento_promedio*, *n_categorias_distintas*), una señal de tendencia (*ratio_actividad_reciente*, que compara el monto facturado en la mitad más reciente de la ventana de observación frente a la mitad anterior, con una variable auxiliar *es_cliente_unica_compra* para no perder información en los casos sin tramo anterior comparable) y atributos estáticos del cliente (*segmento_programa*, *ingresos_mensuales_aprox*, *edad*, *sexo*, *distrito*, *antiguedad_dias*), previamente validados como únicos por *id_cliente*.


El universo de clientes con historial transaccional disponible asciende a 3,641; de ellos, 3,438 cumplieron el criterio de elegibilidad (actividad registrada antes del 31 de agosto de 2025) y conforman la unidad de análisis final del modelo, mientras que 203 clientes quedaron excluidos por no contar con ningún historial previo al corte. Cabe señalar, como hallazgo relevante de control de calidad, que la tasa de abandono efectivamente observada en esta base de modelado fue de **64.49%**, una cifra sustancialmente más alta que el ~23% documentado como patrón de diseño en la generación de los datos sintéticos. El propio notebook incorpora una validación automática que contrasta ambos valores y advierte explícitamente sobre esta desviación, señalando la necesidad de revisar las ventanas y el criterio de elegibilidad antes de continuar; esto sugiere que el criterio de elegibilidad utilizado en este ejercicio (clientes con al menos una compra antes de agosto de 2025) concentra una proporción de clientes de baja actividad mayor a la que existe en la base completa de clientes registrados en el programa.

En cuanto a las transformaciones necesarias antes del modelado, se aplicó una **codificación ordinal** a *segmento_programa* (*Basico* = 0, *Regular* = 1, *Premium* = 2, *Platino* = 3), respetando la jerarquía real de niveles del programa de fidelización; una **codificación binaria** a *sexo*; y una **codificación one-hot** a *distrito*, previa agrupación de los distritos con una frecuencia inferior al 2% en una categoría residual, para evitar la proliferación de columnas dispersas de bajo valor predictivo. El conjunto final quedó compuesto por 26 variables predictoras. Antes de continuar, se ejecutó una verificación explícita de ausencia de variables prohibidas (identificadores, fechas crudas o cualquier campo con información posterior al 31 de agosto de 2025), confirmando que el vector de variables está libre de fuga de datos. Finalmente, se realizó una **partición train/test estratificada** (75%/25%) por la variable *churn*, fijando la semilla del proyecto (*SEMILLA* = 20) para garantizar reproducibilidad, y se aplicó un **escalado estándar** (media 0, desviación 1) a las variables numéricas continuas, ajustado exclusivamente sobre el conjunto de entrenamiento para evitar la filtración de estadísticas del conjunto de prueba.

Tabla de Elegibilidad de Clientes para el Modelo de Abandono



Distribución de la Variable Objetivo: Abandono del Programa de Fidelización




6.3. Modelos implementados

Siguiendo el diseño metodológico aprobado, se entrenaron y compararon tres algoritmos de clasificación supervisada, ordenados de menor a mayor complejidad:

- **Regresión Logística:** actúa como modelo base e interpretable, ya que estima directamente la probabilidad de abandono a partir de una combinación lineal de las variables predictoras, transformada mediante la función logística. Se eligió como punto de partida porque sus coeficientes tienen signo y magnitud interpretables, ofreciendo una primera aproximación directa a los "detonantes" del abandono. Se configuró con `class_weight='balanced'` para compensar el desbalance moderado de clases (~64%/36%) sin recurrir a técnicas de sobre o submuestreo, preservando así la interpretabilidad de los coeficientes.
- **Árbol de Decisión:** captura relaciones no lineales entre las variables mediante una secuencia de reglas de decisión explícitas (por ejemplo, "si `recencia_dias` es mayor a X e `ingresos_mensuales_aprox` es menor a Y, entonces..."), lo que lo hace especialmente útil para comunicar hallazgos al equipo directivo de forma visual y sin necesidad de conocimientos estadísticos avanzados. Se limitó su profundidad máxima a 6 niveles (`max_depth=6`) como control razonable de sobreajuste, manteniendo el mismo balanceo de clases y la misma semilla del proyecto que los demás modelos.

Random Forest: es un modelo de ensamble compuesto por 300 árboles de decisión (`n_estimators=300`), cuyas predicciones individuales se combinan por votación. Se eligió como tercer modelo porque, al promediar múltiples árboles entrenados sobre distintas muestras y subconjuntos de variables, típicamente mejora la capacidad de generalización frente a un árbol individual y ofrece una medida más robusta de importancia de variables, a costa de una menor interpretabilidad directa que los dos modelos anteriores.

Los tres modelos se entrenaron sobre el mismo conjunto de entrenamiento (2,578 clientes) y se evaluaron sobre el mismo conjunto de prueba (860 clientes), preservando en ambos casos una proporción de churn cercana al 64.5% gracias a la partición estratificada, lo que garantiza que la comparación de desempeño entre modelos sea justa y no esté sesgada por diferencias en la composición de clases.



6.4. Evaluación del desempeño

Para comparar los tres modelos se utilizaron cinco métricas estándar de clasificación, todas calculadas sobre el conjunto de prueba:

- **Accuracy (exactitud):** proporción total de predicciones correctas sobre el total de clientes evaluados. Es la métrica más intuitiva, pero puede ser engañosa en problemas con clases desbalanceadas, ya que un modelo que simplemente prediga la clase mayoritaria puede lograr una exactitud alta sin ser útil para el negocio.
- **Precision (precisión):** de todos los clientes que el modelo marcó como "va a abandonar", qué proporción efectivamente abandonó. Una precisión alta implica pocas falsas alarmas, es decir, pocos clientes sanos contactados innecesariamente con una oferta de retención.
- **Recall (sensibilidad o exhaustividad):** de todos los clientes que efectivamente abandonaron, qué proporción fue correctamente identificada por el modelo. Es la métrica más crítica para este caso de negocio, porque un cliente que abandona y no

es detectado (falso negativo) representa una pérdida de ingresos que ya no puede remediarse con una campaña de retención.



- **F1-score:** media armónica entre precisión y recall, utilizada como respaldo del criterio de selección para evitar escoger un modelo que sacrifique demasiada precisión a cambio de recall (o viceversa).
- **ROC-AUC:** área bajo la curva ROC, que resume la capacidad del modelo para separar clientes que abandonan de los que no, a lo largo de todos los posibles umbrales de decisión, no solo en el umbral de 0.5 usado por defecto.

Adicionalmente, se generaron matrices de confusión para los tres modelos, que desglosan los aciertos y errores sobre el mismo conjunto de prueba distinguiendo entre falsos positivos (clientes sanos marcados como riesgo) y falsos negativos (clientes que abandonan y el modelo no detecta), siendo esta última celda la de mayor costo de negocio.


La tabla comparativa de métricas obtenida fue la siguiente:

Modelo	Accuracy	Precision	Recall	F1-score	ROC-AUC
Regresión Logística	0.6651	0.8000	0.6414	0.7120	0.7435
Árbol de Decisión	0.6767	0.8386	0.6180	0.7116	0.7669
Random Forest	0.7186	0.7570	0.8306	0.7921	0.7818

Siguiendo el criterio aprobado en el diseño metodológico, la métrica principal de selección fue el ****Recall de la clase churn****, respaldada por el F1-score, debido a que el costo de negocio de no detectar a un cliente que sí abandonará (falso negativo) es mayor que el costo de contactar innecesariamente con una oferta de retención a un cliente que en realidad no iba a abandonar (falso positivo). Bajo este criterio, ****Random Forest resultó ser el modelo con mejor desempeño****, alcanzando un recall de 0.831 (es decir, detecta correctamente a 83 de cada 100 clientes que efectivamente abandonan) y el F1-score más alto (0.792), además del mayor ROC-AUC (0.782) entre los tres modelos. La Regresión Logística y el Árbol de Decisión, si bien lograron una precisión nominal superior (0.80 y 0.84 respectivamente, frente a 0.76 de Random Forest), lo hicieron a costa de un recall considerablemente menor (0.641 y 0.618), lo que en términos de negocio implica dejar sin detectar a una proporción mayor de clientes que efectivamente abandonarán el programa. Esta diferencia se visualiza también en las matrices de confusión, donde Random Forest exhibe la menor cantidad de falsos negativos de los tres modelos, confirmando su idoneidad para este caso de uso específico.



6.5. Interpretación del modelo




Una vez seleccionado Random Forest como modelo recomendado, se extrajo su ranking de importancia de variables (basado en la reducción de impureza aportada por cada variable a lo largo de los 300 árboles del ensamble), con el fin de traducir el modelo ganador en una lista priorizada de "detonantes" del abandono, cumpliendo así el mandato del informe de no solo predecir el fenómeno, sino explicarlo. Como verificación adicional de robustez metodológica, el notebook contrasta el Top 5 de variables más relevantes de los tres modelos entrenados (Regresión Logística, Árbol de Decisión y Random Forest) de forma simultánea, encontrando que `segmento\_programa` es la única variable que aparece consistentemente entre las cinco más importantes en los tres algoritmos, sin importar su distinta naturaleza matemática. Esta coincidencia entre modelos tan diferentes en su formulación es una señal de que el nivel de vinculación del cliente con el programa de fidelización es, en efecto, un driver robusto y no un artefacto de un único algoritmo.

Por su parte, la variable identificada como la de mayor importancia individual dentro del modelo Random Forest seleccionado fue `ingresos\_mensuales\_aprox`. Desde la perspectiva del negocio, este hallazgo resulta coherente con la lógica de retail y de programas de fidelización: los clientes con menor poder adquisitivo relativo tienden a mostrar patrones de consumo más esporádicos y más sensibles a la necesidad económica inmediata, lo que los hace más propensos a discontinuar su participación activa en el programa cuando no perciben un beneficio económico claro y sostenido. Este resultado, junto con la relevancia consistente de `segmento\_programa` en los tres modelos, confirma a nivel de datos la sospecha inicial planteada por el directorio de

FISIMart: el riesgo de abandono no se distribuye de manera uniforme entre la base de clientes, sino que se concentra en los segmentos de menor vinculación y menor ingreso, tal como también se evidenció de forma exploratoria en el análisis de tasa de abandono por segmento del programa y en la comparación de distribuciones por clase.

En conjunto, estos resultados permiten trazar un perfil de riesgo relativamente nítido: el cliente con mayor probabilidad de abandonar el programa de fidelización de FISIMart tiende a ser aquel ubicado en los segmentos de menor jerarquía del programa (típicamente Básico), con un nivel de ingresos mensuales aproximados por debajo del promedio de la base, y —de forma consistente con la lógica RFM incorporada en el vector de variables— con una recencia de compra más alta y una frecuencia de compra más baja que el cliente promedio. Este perfil no debe interpretarse como una sentencia determinista sobre el comportamiento de un cliente individual, sino como una guía probabilística que permite priorizar los recursos limitados del equipo de retención hacia los casos de mayor riesgo relativo.



6.6. Recomendaciones de negocio

- Se recomienda adoptar el modelo Random Forest entrenado en esta sección como insumo de un **proceso mensual de scoring de riesgo de abandono**, ejecutándolo con una fecha de corte móvil (por ejemplo, al cierre de cada mes) en lugar de utilizarlo como un análisis único y estático; esto permitiría al equipo de retención

anticipar campañas de fidelización antes de que el cliente deje de comprar por completo, en vez de reaccionar únicamente después de confirmado el abandono, cuando ya no existe posibilidad de revertirlo.

- Dado que `segmento_programa` demostró ser la variable más consistentemente relevante entre los tres modelos evaluados, se recomienda que el presupuesto de retención se asigne de forma diferenciada por nivel del programa de fidelización, concentrando el mayor esfuerzo y la mayor frecuencia de contacto en los clientes del segmento Básico, en lugar de continuar con el esquema actual de promociones masivas y sin personalización que fue señalado como una de las problemáticas centrales del negocio.
- Considerando que `ingresos_mensuales_aprox` resultó ser la variable individual de mayor importancia en el modelo seleccionado, se recomienda diseñar incentivos de retención económicamente diferenciados según el rango de ingresos aproximado del cliente, por ejemplo, ofreciendo beneficios de bajo costo pero alta percepción de valor (cupones de recompra, envío gratuito, acumulación acelerada de puntos) a los clientes de menores ingresos, en lugar de descuentos directos sobre el precio que erosionan el margen sin necesariamente aumentar la lealtad.
- Puesto que la métrica priorizada para seleccionar el modelo fue el Recall de la clase churn —dado que el costo de negocio de no detectar a un cliente que abandonará es mayor que el de contactar innecesariamente a uno que no lo hará—, se recomienda que el equipo de retención dimensione su capacidad operativa asumiendo que el modelo, aun siendo el de mejor desempeño relativo, dejará sin detectar a una fracción de los clientes en riesgo (falsos negativos); por ello, conviene complementar el scoring del modelo con alertas operativas simples basadas en recencia y frecuencia de compra, que fueron las variables con la separación más marcada entre clases en el análisis exploratorio previo al modelado.
- Se recomienda dar seguimiento periódico a la estabilidad del ranking de variables más importantes cada vez que el modelo sea re-entrenado con datos más recientes; si el conjunto de "detonantes" cambia de forma significativa entre ejecuciones sucesivas (por ejemplo, si `ingresos_mensuales_aprox` o `segmento_programa` dejan de figurar entre las variables más relevantes), esto podría indicar un cambio estructural en el comportamiento de los clientes que amerite revisar tanto el modelo como las hipótesis de negocio que lo sustentan.
- Finalmente, se recomienda documentar como supuesto de diseño —y no como hallazgo validado con datos históricos multiperiodo— el hecho de que `segmento_programa` se trató como un atributo estático anterior al abandono; en la medida en que FISIMart acumule más historia transaccional, convendría evaluar si los clientes migran de segmento antes de abandonar, lo cual permitiría enriquecer el modelo con una variable de tendencia de segmento en lugar de un valor fijo en el tiempo.

7. Parte 4 — Segmentación: RFM, clusters, perfiles y estrategias.

Con el objetivo de responder a la pregunta de negocio sobre qué segmentos de clientes existen y cómo debería tratarse a cada uno, se implementó un modelo de segmentación no supervisada basado en el análisis RFM (Recency, Frequency, Monetary) combinado con el algoritmo de agrupamiento K-Means. Este enfoque permite descubrir arquetipos de comportamiento de compra sin partir de etiquetas predefinidas, complementando el análisis predictivo de deserción abordado previamente.

7.1. Metodología: construcción del RFM y clustering

El análisis se calculó sobre los 3,641 clientes que registraron al menos una compra dentro del horizonte de estudio, de un total de 5,000 clientes inscritos en el programa de fidelización. Los 1,359 clientes restantes (27.2%) no presentan ninguna transacción asociada, por lo que carecen de valores RFM calculables y se excluyeron del modelo de clustering, tratándose como un grupo aparte denominado "Sin actividad / Nunca activaron" para efectos de las recomendaciones comerciales.

Las tres métricas RFM se definieron de la siguiente manera:

- Recency: número de días transcurridos entre la última compra de cada cliente y la fecha de corte establecida en 2026-01-01 (día siguiente a la última venta registrada en el dataset, 2025-12-31). Un valor menor indica un cliente más reciente y, por tanto, más activo.
- Frequency: número de tickets o boletas únicas (id_venta distintos) emitidas por cada cliente durante el periodo de análisis.
- Monetary: suma total del importe facturado por cada cliente.

Sobre estas tres variables se asignaron puntajes del 1 al 5 por quintiles, invirtiendo la escala de Recency para que un menor número de días correspondiera a un puntaje más alto. Posteriormente, dado que K-Means es sensible a la escala de las variables, las tres métricas se estandarizaron mediante StandardScaler antes de ajustar el modelo.

Para determinar el número óptimo de clusters se aplicó el método del codo sobre la inercia, complementado con el coeficiente de silueta (silhouette score). La inercia se aplanaba de forma clara a partir de $k=4$, y este valor obtiene un coeficiente de silueta de 0.43, indicativo de una estructura de agrupamiento moderada y consistente con la separación de cuatro arquetipos de negocio interpretables. En consecuencia, se seleccionó $k=4$ y se fijó la semilla `random_state=20` para garantizar la reproducibilidad del modelo, en línea con la semilla global del proyecto.




Figura. Método del codo y coeficiente de siluet




Figura. Dispersión RFM de los clientes coloreada por clúster

7.2. Segmentos resultantes y perfiles

El modelo K-Means produjo cuatro segmentos de clientes claramente diferenciados, con un gradiente monótono y coherente: a medida que la Recency empeora (más días sin comprar), disminuyen de forma consistente tanto la frecuencia de compra como el gasto acumulado. La siguiente tabla resume el perfil de cada segmento:

Segmento	% clientes	Recency media	Frequency media	Monetary media	Perfil demográfico
Campeones	7.0% (254)	56.6 días	11.1 boletas	S/ 2,855	Ingreso medio S/ 6,667; moda Platino
Leales	23.9% (870)	93.7 días	5.7 boletas	S/ 1,399	Ingreso medio S/ 6,390; moda Platino
En Riesgo	39.7% (1,446)	124.8 días	2.2 boletas	S/ 507	Ingreso medio S/ 6,567; moda Platino

Perdidos	29.4% (1,071)	468.5 días	1.6 boletas	S/ 362	Ingreso medio S/ 5,586; moda Básico
----------	---------------	------------	-------------	--------	--




Figura. Distribución de clientes por segmento




Figura 08. Heatmap comparativo de perfiles RFM por segmento

El segmento Campeones concentra a los mejores clientes de la empresa: compran con la mayor frecuencia (11.1 boletas en promedio), lo hacen recientemente y aportan el mayor valor monetario (S/ 2,855). Los Leales representan una base sólida y recurrente de valor intermedio. El segmento En Riesgo es el más numeroso (39.7%) y agrupa a clientes cuya actividad se ha desacelerado notablemente, mientras que el segmento Perdidos reúne a los clientes con mayor tiempo sin comprar (468.5 días en promedio) y el menor valor monetario.

7.3. Hallazgo clave: validación del diseño del dataset

El resultado más relevante de la segmentación es que capturó de forma precisa el patrón de deserción que fue inyectado deliberadamente durante la generación de datos sintéticos (sección 3.3). Se verificó que el 22.9% de los 5,000 clientes pertenece al segmento de programa Básico con ingresos por debajo de la mediana, cifra prácticamente idéntica al ~23% definido en el diseño del churn, y que el 68% de estos clientes no ha realizado ninguna compra desde el 2025-09-01.

Este patrón de abandono quedó concentrado casi en su totalidad dentro del clúster Perdidos, que resulta ser el único segmento donde "Básico" es la moda del programa de fidelización (32.2%, frente a valores del 12% al 19% en los demás segmentos) y donde el ingreso promedio es el más bajo de los cuatro grupos (S/ 5,586). Esto confirma que la simulación de deserción del segmento Básico de bajos ingresos, correlacionada con menores ingresos mensuales y con el cese de actividad en los últimos cuatro meses de 2025, quedó correctamente aislada por el algoritmo de clustering. Este hallazgo conecta directamente con el análisis de clasificación del punto 6, donde este mismo comportamiento constituye la firma analítica de la variable objetivo de abandono.

7.4. Estrategias diferenciadas por segmento

A partir del perfil de cada grupo, se proponen las siguientes estrategias de negocio orientadas a maximizar el valor de vida del cliente y a mitigar la deserción:

- **Campeones:** consolidar su fidelidad mediante un programa VIP con acceso anticipado a promociones, incentivos de upgrade al nivel Platino y un programa de referidos que aproveche su alto compromiso para captar nuevos clientes de calidad.
- **Leales:** impulsar la venta cruzada apoyándose en las reglas de asociación identificadas en la Parte 5 (notebook 05), mediante bundles por categoría y recordatorios de recompra que incrementen su frecuencia y ticket promedio.
- **En Riesgo:** al ser el segmento más grande, representa la mayor oportunidad de impacto. Se recomiendan descuentos de activación aplicables a la segunda compra, notificaciones push de productos de alta rotación y beneficios como envío gratuito a partir de una canasta mínima, con el fin de reactivar la frecuencia antes de que migren al segmento Perdidos.

- **Perdidos:** desplegar una campaña de reconquista tipo "te extrañamos" con un descuento agresivo de único uso, acompañada de una encuesta de motivo de abandono y ofertas de menor ticket de entrada adecuadas al perfil de bajos ingresos. Dado el bajo retorno esperado de este grupo, se recomienda excluirlo de campañas premium de alto costo para optimizar el presupuesto de marketing.
- **Sin actividad / Nunca activaron:** para los 1,359 clientes inscritos que nunca registraron una compra, se recomienda una campaña de activación de primera compra (cupón de bienvenida) y una revisión de la calidad del registro, ya que un volumen elevado de altas sin conversión puede señalar fricciones en el proceso de onboarding del programa de fidelización.

8. Parte 5 — Asociación: reglas y propuestas de venta cruzada.

8.1. Metodología: construcción de canastas y minería de reglas:

Para descubrir patrones de compra conjunta se trabajó a nivel de producto (SKU), en lugar de categoría, con el fin de detectar pares concretos de artículos accionables en bundles, cross-sell en checkout y recomendaciones en el canal Online.

Construcción de transacciones. Se agruparon las líneas de Fact_Ventas por boleta (id_venta), obteniendo 12,750 boletas únicas sobre un universo de 25,413 líneas de venta y 553 productos distintos. Dado que las reglas de asociación requieren co-ocurrencia entre al menos dos SKUs, se excluyeron las 3,252 boletas de un solo producto (canastas unitarias), quedando 9,498 transacciones multi-ítem disponibles para la minería, con un tamaño promedio de canasta de 2.33 ítems distintos.

Codificación one-hot. Las transacciones se codificaron mediante TransactionEncoder de mlxtend, generando una matriz booleana de 9,498 transacciones × 549 ítems, donde cada celda indica la presencia o ausencia de un producto en la boleta.

Minería de itemsets frecuentes. Se aplicaron los algoritmos Apriori y FP-Growth en paralelo, con un soporte mínimo de 0.1% (0.001). Este umbral se eligió considerando que, a nivel SKU, el espacio combinatorio es muy disperso (~550 productos distintos), por lo que un soporte de 0.1% exige al menos 10 co-compras del par para ser considerado frecuente. Ambos algoritmos coincidieron en identificar 379 itemsets frecuentes, validando la consistencia del resultado independientemente del método de búsqueda.

Generación y filtrado de reglas. Sobre los itemsets frecuentes se generaron reglas de asociación con mlxtend.association_rules, aplicando tres criterios de filtrado:

- Confianza mínima de 3%: a nivel SKU los pares exactos se repiten con menor frecuencia que a nivel categoría, por lo que un umbral más permisivo que el habitual (usualmente 30%) era necesario para no descartar patrones válidos.
- Lift superior a 1: asegura que el consecuente aparece más de lo esperable por azar, descartando asociaciones triviales o negativas.

Bajo estos criterios se obtuvieron 38 reglas de asociación relevantes, que constituyen la base del análisis presentado a continuación.

8.2. Reglas de Asociación:

Se presenta la frecuencia individual de los productos más relevantes en las reglas de asociación encontradas, como referencia para dimensionar su participación en el total de transacciones.

Producto	Support
Producto Conservas 115	0.053064
Producto Jabones 72	0.048747
Producto Organizadores 22	0.046852
Producto Dental 97	0.044430
Producto Cargadores 87	0.043062
Producto Cervezas 95	0.039271
Producto Jugos 3	0.037797
Producto Arroz y Menestras 2	0.037166
Producto Utensilios 73	0.035692
Producto Arroz y Menestras 74	0.034744
Producto Utensilios 14	0.033586
Producto Accesorios 92	0.031796
Producto Jugos 101	0.031375
Producto Cervezas 106	0.030849
Producto Cargadores 21	0.030217

Para descubrir patrones de compra conjunta en FISIMart S.A.C., se aplicó el algoritmo Apriori sobre las transacciones de venta a nivel de producto individual (SKU), filtrando las reglas resultantes por un lift superior a 1 y priorizando aquellas con mayor fuerza de asociación. El análisis identificó 38 reglas de asociación relevantes entre productos específicos del catálogo.

Antecedente	Consecuente	Support	Confidence	Lift
Producto Cervezas 29 (Bebidas)	Producto Dental 97 (Cuidado Personal)	0.001053	0.085470	1.923685
Producto Accesorios 92 (Tecnología)	Producto Accesorios 82 (Tecnología)	0.001053	0.033113	1.776855
Producto Accesorios 82 (Tecnología)	Producto Accesorios 92 (Tecnología)	0.001053	0.056497	1.776855
Producto Utensilios 49 (Hogar)	Producto Aguas 117 (Bebidas)	0.001158	0.041667	1.576693
Producto Aguas 117 (Bebidas)	Producto Utensilios 49 (Hogar)	0.001158	0.043825	1.576693
Producto Jabones 4 (Cuidado Personal)	Producto Jugos 101 (Bebidas)	0.001158	0.042146	1.343285
Producto Jugos 101 (Bebidas)	Producto Jabones 4 (Cuidado Personal)	0.001158	0.036913	1.343285
Producto Gaseosas 54 (Bebidas)	Producto Aguas 117 (Bebidas)	0.001053	0.035211	1.332417
Producto Aguas 117 (Bebidas)	Producto Gaseosas 54 (Bebidas)	0.001053	0.039841	1.332417
Producto Dental 97 (Cuidado Personal)	Producto Cervezas 95 (Bebidas)	0.002316	0.052133	1.327497
Producto Cervezas 95 (Bebidas)	Producto Dental 97 (Cuidado Personal)	0.002316	0.058981	1.327497
Producto Organizadores 22 (Hogar)	Producto Utensilios 49 (Hogar)	0.001685	0.035955	1.293565
Producto Utensilios 49 (Hogar)	Producto Organizadores 22 (Hogar)	0.001685	0.060606	1.293565
Producto Aguas 51 (Bebidas)	Producto Utensilios 73 (Hogar)	0.001053	0.046083	1.291138
Producto Utensilios 49 (Hogar)	Producto Gaseosas 54 (Bebidas)	0.001053	0.037879	1.266805

8.3. Recomendaciones de venta cruzada

- La regla más fuerte encontrada relaciona la compra de Cervezas 29 con Dental 97 (lift de 1,92), evidenciando un patrón de compra cruzada entre categorías aparentemente distantes (Bebidas y Cuidado Personal); la recomendación de negocio es ubicar un pequeño exhibidor de productos de cuidado bucal cerca de la sección de cervezas y evaluar un bundle promocional tipo "Noche en casa" que combine ambos productos.

- Se identificó una fuerte complementariedad entre Accesorios 82 y Accesorios 92 (lift de 1,78), ambos dentro de la categoría Tecnología, lo que sugiere que los clientes que compran uno tienden a llevar también el otro; la recomendación es reforzar la exhibición conjunta de ambos SKUs en el mismo punto de venta y ofrecer un descuento combinado que incentive la compra del par completo.
- La combinación Utensilios 49 y Aguas 117 (lift de 1,58) revela un patrón de compra de conveniencia que cruza las categorías Hogar y Bebidas, por lo que se recomienda crear una zona de conveniencia cerca de las cajas que agrupe utensilios de cocina con agua embotellada, facilitando la compra por impulso.
- Los productos Jabones 4 y Jugos 101 presentan una afinidad moderada-alta (lift de 1,34), consistente con un patrón de compra familiar o de abastecimiento del hogar; se recomienda diseñar una campaña dirigida a hogares con compras recurrentes de ambas familias de producto, reforzando la relación mediante comunicación personalizada.
- La pareja Gaseosas 54 y Aguas 117 (lift de 1,33) muestra un comportamiento de complementariedad dentro del propio pasillo de bebidas, por lo que se sugiere un exhibidor mixto de formato familiar y una promoción de segundo producto de bebida a mitad de precio.
- Finalmente, la relación entre Dental 97 y Cervezas 95 (lift de 1,33, con el mayor soporte entre las reglas encontradas) confirma que este patrón de cruce entre Cuidado Personal y Bebidas no es un caso aislado; se recomienda extender el cross-merchandising observado en la primera regla a más puntos de venta.

9. Parte 6 — Regresión: pronóstico, métricas y recomendaciones.

9.1. Objetivo y alcance

El objetivo de esta parte es responder a la pregunta de negocio: ¿cuál será la demanda/venta esperada para planificar inventario y campañas? Para ello se construye una serie temporal de ventas diarias a partir del datamart depurado en la Parte 1, se enriquece con variables predictoras de calendario, promociones y comportamiento histórico, y se comparan tres algoritmos de regresión bajo un esquema de validación temporal que respeta el orden cronológico de los datos, evitando la fuga de información desde el futuro hacia el pasado.

9.2. Fuentes de datos utilizadas


Antes de construir el modelo se verificó que los datos ya se encuentran libres de nulos y duplicados exactos, y que cubren el rango completo del 1 de enero de 2024 al 31 de diciembre de 2025 (dos años de operación). La siguiente tabla resume las fuentes utilizadas y su tamaño:

Tabla	Filas	Columnas	Uso en esta parte
Fact_Ventas.csv	25,413	12	Base para construir la serie diaria de ventas y el indicador de promoción activa
Dim_Tiempo.csv	731	7	Calendario base para la serie diaria y el indicador de feriado
Dim_Producto.csv	600	7	Categoría de producto, para la serie objetivo secundaria por categoría
Dim_Promocion.csv	41	6	Referencia de promociones (uso indirecto vía id_promocion en Fact_Ventas)

9.3. Definición de la variable objetivo

Se definió como variable objetivo el importe total de ventas agregado por día (ventas_dia), calculado como la suma del campo importe de Fact_Ventas agrupado por fecha. Trabajar a nivel diario resulta el más útil para la planificación de inventario y campañas de corto plazo, y ofrece un número suficiente de observaciones (731 días) para entrenar y validar modelos de series de tiempo.

De forma complementaria, se construyó una serie objetivo secundaria de ventas diarias por categoría de producto (Abarrotes, Bebidas, Cuidado Personal, Hogar y Tecnología), que puede emplearse para pronósticos segmentados en futuras iteraciones del tablero.




La serie muestra un comportamiento estacional claro, con picos de ventas alrededor de julio y diciembre —coherentes con las Fiestas Patrias y la campaña navideña simuladas en la generación de datos sintéticos— y una tendencia creciente hacia el segundo año de operación.

9.4. Construcción de variables predictoras

A partir del datamart se construyeron cinco familias de variables predictoras (features), siguiendo lo solicitado en la sección 12.1 de la guía del proyecto:

Familia	Variables construidas	Descripción
Componentes temporales	dia_semana_num, es_fin_semana, dia_anio	Ubican cada observación dentro del calendario y distinguen días laborables de fines de semana.
Estacionalidad cíclica	mes_sin, mes_cos, dia_semana_sin, dia_semana_cos, dia_anio_sin, dia_anio_cos	Codificación seno/coseno que evita discontinuidades entre diciembre y enero, o entre domingo y lunes.
Feriados	es_feriado	Indicador binario tomado directamente de Dim_Tiempo.
Promoción	pct_lineas_con_promo	Proporción de líneas de venta del día bajo alguna promoción activa (distinta de PROMO_NONE).
Rezagos y medias móviles	lag_1, lag_7, lag_14, media_movil_7, media_movil_14	Ventas de días anteriores y su promedio reciente, para capturar la dependencia temporal directa y suavizar el ruido diario.

Los rezagos y medias móviles requieren histórico previo, por lo que las primeras 14 observaciones de la serie se descartaron por falta de datos suficientes, quedando 717 filas disponibles para el modelado (de las 731 originales).




El análisis de correlación confirma que los rezagos y las medias móviles son las variables con mayor relación lineal con la variable objetivo, mientras que las variables cíclicas de estacionalidad muestran una correlación moderada.

9.5. División temporal de entrenamiento y prueba

A diferencia de una división aleatoria, en series de tiempo el conjunto de prueba debe corresponder al periodo más reciente y el de entrenamiento al periodo pasado, de modo que se simule el escenario real de pronóstico y se evite la fuga de información desde el futuro. Se aplicó un corte 80/20 sobre las 717 filas disponibles:

Conjunto	N.º de días	Fecha de inicio	Fecha de fin
Entrenamiento	573	2024-01-15	2025-08-09
Prueba (validación)	144	2025-08-10	2025-12-31



9.6. Modelos evaluados


Se entrenaron y compararon tres algoritmos de regresión, todos con semilla fija (`random_state = 42`) para garantizar la reproducibilidad de los resultados:

- Regresión Lineal: modelo base, simple e interpretable, útil como referencia de comparación.
- Random Forest Regressor (300 árboles): captura relaciones no lineales e interacciones entre variables.
- Gradient Boosting Regressor: modelo de boosting, orientado a capturar patrones complejos de forma secuencial.

9.7. Resultados y comparación de métricas

Cada modelo fue evaluado sobre el conjunto de prueba (144 días) con las cuatro métricas estándar de regresión solicitadas por la guía: MAE, RMSE, MAPE y R^2 . Los resultados obtenidos fueron los siguientes:

Modelo	MAE (S/)	RMSE (S/)	MAPE (%)	R^2
Regresión Lineal	727.44	965.82	24.96	0.842
Random Forest	980.20	1,238.89	32.98	0.739
Gradient Boosting	1,011.32	1,457.28	30.66	0.640



La Regresión Lineal obtuvo el mejor desempeño en las cuatro métricas, superando a los modelos de árboles. Esto sugiere que, para los datos sintéticos de FISIMart, la relación entre las variables predictoras (especialmente los rezagos, la estacionalidad y los feriados) y las ventas diarias es predominantemente lineal y aditiva, sin interacciones complejas que los modelos de árboles puedan aprovechar mejor.

9.8. Selección del mejor modelo y análisis del pronóstico

El modelo sigue razonablemente la tendencia general de la serie, incluyendo el incremento de ventas hacia el cierre de año, aunque presenta mayor error en días puntuales de alta variabilidad. A modo de referencia, se muestra una muestra de los primeros registros de la tabla real vs. pronóstico exportada:

Fecha	Ventas reales (S/)	Pronóstico (S/)	Error absoluto (S/)	Error (%)
2025-08-10	3,643.26	2,619.22	1,024.04	28.11
2025-08-11	2,771.10	3,054.02	282.92	10.21

2025-08-12	2,651.79	2,800.74	148.95	5.62
2025-08-13	1,735.12	2,766.62	1,031.50	59.45
2025-08-14	2,381.60	2,153.79	227.81	9.57

9.9. Interpretación de variables y hallazgos de negocio

Al tratarse de un modelo lineal, la interpretación de negocio se apoya directamente en sus coeficientes, que indican cuánto varía la venta diaria pronosticada (en soles) ante un cambio unitario de cada variable, manteniendo las demás constantes:

Variable	Coeficiente
es_feriado	611.79
es_fin_semana	308.03
mes_cos	-216.59
pct_lineas_con_promo	-160.87
dia_anio_cos	154.59
dia_semana_sin	129.34
dia_semana_cos	125.62
mes_sin	-60.23
dia_anio_sin	-56.03
media_movil_7	0.77
lag_1	0.36
lag_7	-0.12
media_movil_14	-0.08
lag_14	-0.02

Los principales hallazgos son los siguientes:

- Feriados y fines de semana elevan la venta esperada: ser feriado aporta en promedio S/ 611.79 adicionales al día, y ser fin de semana aporta S/ 308.03 adicionales, el efecto individual más fuerte del modelo.
- La estacionalidad mensual (mes_sin, mes_cos, dia_anio_sin, dia_anio_cos) recoge los picos de julio y diciembre observados en la Figura 1, confirmando el patrón de estacionalidad esperado para un retail peruano.
- El indicador de promoción (pct_lineas_con_promo) presenta un coeficiente negativo, lo que sugiere que, en los datos sintéticos actuales, una mayor proporción de líneas con promoción no se traduce directamente en un mayor importe total del día; esto amerita revisión conjunta con el equipo, ya que podría deberse a que las promociones se concentran en productos de menor valor unitario.

- Los rezagos y medias móviles, si bien tienen coeficientes individuales pequeños en el modelo lineal, muestran alta correlación con la variable objetivo (ver Figura 2); su aporte principal es reducir el error del modelo capturando la inercia de corto plazo de las ventas.

El MAPE obtenido por el mejor modelo (24.96 %) da una noción directa del error relativo esperado del pronóstico. Este valor debe interpretarse como el margen de seguridad recomendable al planificar el inventario: por ejemplo, mantener un colchón de stock proporcional a este porcentaje sobre la demanda pronosticada, especialmente en fechas cercanas a feriados o campañas.

9.10. Recomendaciones de planificación

- Reforzar el abastecimiento antes de feriados y fines de semana, dado que son los factores con mayor impacto positivo sobre la venta diaria pronosticada.
- Anticipar la reposición de inventario en las semanas previas a julio y diciembre, en línea con el patrón estacional identificado.
- Revisar el diseño de las promociones vigentes junto con el área comercial, dado el coeficiente negativo inesperado de `pct_lineas_con_promo`, para validar si corresponde a un efecto real o a una particularidad de los datos sintéticos generados.
- Utilizar el pronóstico como referencia de planificación, no como cifra exacta: el error medio absoluto de S/ 727.44 por día debe considerarse al definir niveles de stock de seguridad.
- Reentrenar el modelo periódicamente (por ejemplo, cada mes) a medida que se acumulen nuevos datos reales, para mantener la vigencia del pronóstico.

10. Reflexión ética y de integridad; anexo de prompts A y B.

11. Conclusiones, recomendaciones y tabla de contribución por integrante.

11.1. Conclusiones

- El análisis de datos mostró que las ventas y el margen presentan un comportamiento estacional, con mayores resultados en julio y diciembre. Además, se identificó que solo 12 productos generan el 80% de las ventas, evidenciando una alta dependencia de un grupo reducido de productos.
- El modelo de clasificación permitió identificar de forma confiable a los clientes con mayor riesgo de abandono, concentrándose principalmente en el segmento Básico y en aquellos con menores ingresos mensuales.

- La segmentación de clientes identificó cuatro grupos con comportamientos diferenciados (Campeones, Leales, En Riesgo y Perdidos). Los clientes con mayor probabilidad de abandono se ubicaron principalmente en el grupo Perdidos, confirmando la consistencia de los resultados obtenidos.
- El análisis de reglas de asociación detectó oportunidades de venta cruzada entre productos que no pertenecen a la misma categoría, lo que puede contribuir al diseño de promociones y estrategias comerciales más efectivas.
- El modelo de regresión lineal obtuvo el mejor desempeño para pronosticar la demanda diaria, demostrando que factores como la estacionalidad, los fines de semana y el comportamiento reciente de las ventas son suficientes para realizar predicciones con buena precisión.
- En conjunto, los 6 componentes desarrollados (datamart, visualización, clasificación, segmentación, asociación y regresión) demostraron que una solución integrada de inteligencia de negocios proporciona información complementaria y útil para apoyar la toma de decisiones estratégicas en FISIMart S.A.C.
- Debido a que el estudio se realizó con datos sintéticos, los resultados constituyen una prueba de concepto. Antes de su aplicación en un entorno real, es necesario validar los modelos utilizando datos transaccionales de la empresa.

11.2. Recomendaciones

- Migrar del esquema actual de promociones masivas hacia una segmentación de campañas basada en el scoring de abandono y los clústeres RFM, concentrando presupuesto y frecuencia de contacto en los segmentos Básico y En Riesgo.
- Integrar el pronóstico de demanda diaria al calendario de reposición de inventario, anticipando el abastecimiento antes de los picos de julio y diciembre.
- Aprovechar las reglas de asociación para re-diseñar el layout físico de las tiendas y los bundles del canal ecommerce, reduciendo la dependencia de descuentos directos sobre el precio.
- Validar los modelos con datos transaccionales reales antes de su despliegue, dado que los resultados actuales se basan en datos sintéticos con patrones inyectados deliberadamente y deben tratarse como prueba de concepto, no como parámetros de negocio definitivos.
- Formalizar la matriz analítica unificada construida en la Parte 1 como fuente única de verdad para las áreas comercial, de marketing e inventario.

11.3. Tabla de contribución por integrante

Integrante	Rol	% de Contribución	Tareas principales realizadas	Firma
	Líder de proyecto	%		
Luján Vila, Frank José	Ingeniero de datos / Arquitecto de BI	30%	Generación de datos sintéticos, desarrollo el pipeline ETL en Python, modelado estrella en Power BI, cálculo de medidas DAX y el tablero ejecutivo.	
		%		
		%		
		%		
TOTAL	-	100%	-	